

2020 级华东师范大学本科生期末考试

《数据科学与工程数学基础》笔试试卷 2022.9

学院：数据科学与工程学院 考试形式：闭卷 所需时间：120 分钟

考生姓名：_____ 学号：_____ 专业：_____ 任课教师：黄定江

题目	一	二	三	四	五	六	七	八	总分
满分	14	12	13	13	13	12	12	11	100
得分									
阅卷人									

题 1 (14') 已知矩阵

$$\mathbf{M} = \begin{pmatrix} 1 & 0 \\ -2 & 3 \\ 0 & 1 \end{pmatrix}$$

- (1) 计算矩阵 \mathbf{M} 的 1 范数；
- (2) 计算矩阵 \mathbf{M} 的 2 范数；
- (3) 证明：对任意 $\mathbf{A} \in \mathbb{R}^{m \times n}$ ，由

$$\|\mathbf{A}\|_{m_\infty} := \max_{1 \leq i \leq m, 1 \leq j \leq n} |a_{ij}|$$

定义的 $\|\cdot\|_{m_\infty}$ 是 $\mathbb{R}^{m \times n}$ 上的（广义）矩阵范数。

解 (1) $\|\mathbf{M}\|_1 = \max\{1 + \|-2\|, 3 + 1\} = 4$ (3 分)

$$(2) \mathbf{M}^\top \mathbf{M} = \begin{pmatrix} 2 & 2 \\ 2 & 4 \end{pmatrix}$$

$$\lambda_{\max}(\mathbf{M}^\top \mathbf{M}) = 14$$

$$\|\mathbf{M}\|_2 = \sqrt{14}$$
 (4 分)

(3) 非负性: 显然

$$\|\mathbf{A}\|_{m_\infty} := \max_{1 \leq i \leq m, 1 \leq j \leq n} |a_{ij}| \geq 0,$$

而且仅当 $\mathbf{A} = 0$ 时, $\|\mathbf{A}\|_{m_\infty} = 0$. (2 分)

齐次性:

$$\|c \cdot \mathbf{A}\|_{m_\infty} := \max_{1 \leq i \leq m, 1 \leq j \leq n} |c \cdot a_{ij}| = c \max_{1 \leq i \leq m, 1 \leq j \leq n} |a_{ij}| = c \|\mathbf{A}\|_{m_\infty}$$

(2 分)

三角不等式: 考虑 $\|\mathbf{A} + \mathbf{B}\|_{m_\infty}$, 因为

$$|a_{ij} + b_{ij}| \leq |a_{ij}| + |b_{ij}| \leq \max_{1 \leq i \leq m, 1 \leq j \leq n} |a_{ij}| + \max_{1 \leq i \leq m, 1 \leq j \leq n} |b_{ij}|$$

所以

$$\max_{1 \leq i \leq m, 1 \leq j \leq n} |a_{ij} + b_{ij}| \leq \max_{1 \leq i \leq m, 1 \leq j \leq n} |a_{ij}| + \max_{1 \leq i \leq m, 1 \leq j \leq n} |b_{ij}|$$

即 $\|\mathbf{A} + \mathbf{B}\|_{m_\infty} \leq \|\mathbf{A}\|_{m_\infty} + \|\mathbf{B}\|_{m_\infty}$ (3 分)

题 2 (12') 已知矩阵

$$\mathbf{M} = \begin{pmatrix} 1 & -1 & 0 \\ 2 & 4 & 1 \\ 4 & 2 & 1 \end{pmatrix}$$

(1) 求矩阵 \mathbf{M} 的零空间;

(2) 求向量 $\mathbf{x} = (1, 1, 1)^\top$ 在矩阵 \mathbf{M} 的列空间上的正交投影;

- (3) 利用 Householder 变换, 将非零向量 $\mathbf{x} = (1, 1, 1)^\top$ 变为标准向量 $\mathbf{e}_1 = (0, 1, 0)^\top$ 的 $\sqrt{3}$ 倍, 请写出这个 Householder 变换矩阵。

解 (1) 零空间为 $\text{span}\{(1, 1, -6)^T\}$ (3 分)

(2) 列空间为 $\text{span}\{(1, 2, 4)^T, (-1, 4, 2)^T\}$, 若记

$$\mathbf{A} = \begin{pmatrix} 1 & -1 \\ 2 & 4 \\ 4 & 2 \end{pmatrix}$$

故正交投影为 $\mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x} = (1/3, 2/3, 4/3)^\top$ (4 分)

(3)

$$w = \frac{x - \alpha e_1}{\|x - \alpha e_1\|_2}$$

则, 由 $H = (I - 2ww^\top)$ 可得:

$$\mathbf{H} = \begin{pmatrix} \frac{2-\sqrt{3}}{3-\sqrt{3}} & \frac{1}{\sqrt{3}} & -\frac{1}{3-\sqrt{3}} \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} \\ -\frac{1}{3-\sqrt{3}} & \frac{1}{\sqrt{3}} & \frac{2-\sqrt{3}}{3-\sqrt{3}} \end{pmatrix}$$

(5 分)

题 3 (13') 矩阵

$$\mathbf{A} = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{pmatrix}$$

- (1) 计算矩阵 \mathbf{A} 的 SVD 分解;
- (2) 假设 \mathbf{B} 是一个 $n \times d$ 的矩阵, 矩阵 \mathbf{M} 是 $(n+d) \times (n+d)$ 定义为

$$\mathbf{M} = \begin{pmatrix} \mathbf{O} & \mathbf{B}^\top \\ \mathbf{B} & \mathbf{O} \end{pmatrix}$$

显然 \mathbf{M} 是对称矩阵。请证明矩阵 \mathbf{M} 的对角化会产生 \mathbf{B} 的奇异值分解所需的所有信息。

解 (1) 易计算

$$AA^T = \begin{pmatrix} 17 & 8 \\ 8 & 17 \end{pmatrix}$$

求得其特征值为 25, 9。对应的特征向量分别为 $(1/\sqrt{2}, 1/\sqrt{2})^T, (-1/\sqrt{2}, 1/\sqrt{2})^T$ ，因此，

$$U = \begin{pmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$

(4 分)

由 $A^T U$ 与 V 的关系可直接计算出

$$V = \begin{pmatrix} 1/\sqrt{2} & -1/3\sqrt{2} & -2/3 \\ 1/\sqrt{2} & 1/3\sqrt{2} & 2/3 \\ 0 & -4/3\sqrt{2} & 1/3 \end{pmatrix}$$

(3 分)

(2) B 的奇异值分解所需要的信息为 $B^T B$ 的特征向量和 BB^T 的特征向量，以及对应的特征值。现假设对应于特征值为 $\lambda^2 (\lambda > 0)$ 的 $B^T B$ 的特征向量为 $\mathbf{x}_1 (\|\mathbf{x}_1\|_2 = 1)$, BB^T 的特征向量为 $\mathbf{x}_2 (\|\mathbf{x}_2\|_2 = 1)$ 。因此， $B^T B \mathbf{x}_1 = \lambda^2 \mathbf{x}_1$ 以及 $BB^T \mathbf{x}_2 = \lambda^2 \mathbf{x}_2$ 。故

$$(BB^T)B\mathbf{x}_1 = \lambda^2 B\mathbf{x}_1$$

所以存在 k 使得 $B\mathbf{x}_1 = k\mathbf{x}_2$ 。由于 $\|\mathbf{x}_1\|_2 = \|\mathbf{x}_2\|_2 = 1$ ，可得 $k = \lambda$ ，即 $B\mathbf{x}_1 = \lambda\mathbf{x}_2$ 。同理有 $B^T \mathbf{x}_2 = \lambda\mathbf{x}_1$ 。

(3 分)

下面证明 $\mathbf{x} = \begin{pmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{pmatrix}$ 是矩阵 M 的特征值为 λ 的特征向量。易计算

$$M\mathbf{x} = \begin{pmatrix} 0 & B^T \\ B & 0 \end{pmatrix} \begin{pmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{pmatrix} = \begin{pmatrix} B^T \mathbf{x}_2 \\ B\mathbf{x}_1 \end{pmatrix} = \lambda \begin{pmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{pmatrix}$$

因此， B 的奇异值分解信息包含在 M 的对角化过程中。

(3 分)

题 4 (13') 完成下列函数求导或梯度：

- (1) 求激活函数 $\sigma(x) = \frac{1}{1+e^{-x}}$ 的导数;
- (2) 求函数 $f(\mathbf{X}) = \text{Tr}(\mathbf{X}^{-1})$ 对 \mathbf{X} 的梯度, 其中 $\mathbf{X} \in \mathbb{R}^{m \times n}$ 。
- (3) 若非奇异矩阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$, $\mathbf{x} \in \mathbb{R}^{n \times 1}$, $\mathbf{y} \in \mathbb{R}^{n \times 1}$, 求函数 $f(\mathbf{A}) = \mathbf{y}^\top \mathbf{A}^{-1} \mathbf{x}$ 对 \mathbf{A} 的梯度。

解 (1) $\sigma'(x) = \frac{e^{-x}}{(1+e^{-x})^2} = \sigma(x)(1 - \sigma(x))$ (4 分)

(2) 因为

$$0 = dI = d(\mathbf{X}\mathbf{X}^{-1}) = d\mathbf{X}\mathbf{X}^{-1} + \mathbf{X}d\mathbf{X}^{-1}$$

$$\mathbf{X}d\mathbf{X}^{-1} = -d\mathbf{X}\mathbf{X}^{-1}$$

$$d\mathbf{X}^{-1} = -\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}$$

所以

$$\begin{aligned} d\text{Tr}(\mathbf{X}^{-1}) &= \text{Tr}(d\mathbf{X}^{-1}) \\ &= \text{Tr}(-\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}) \\ &= \text{Tr}(-(\mathbf{X}^{-1})^2 d\mathbf{X}) \end{aligned}$$

即

$$\frac{\partial \text{Tr}(\mathbf{X}^{-1})}{\partial \mathbf{X}} = -(\mathbf{X}^{-T})^2$$

(5 分)

(3)

$$\begin{aligned} df(\mathbf{A}) &= \text{Tr}(d\mathbf{y}^\top \mathbf{A}^{-1} \mathbf{x}) \\ &= \text{Tr}(\mathbf{y}^\top d\mathbf{A}^{-1} \mathbf{x}) \\ &= \text{Tr}(-\mathbf{y}^\top \mathbf{A}^{-1} d\mathbf{A} \mathbf{A}^{-1} \mathbf{x}) \\ &= \text{Tr}(-\mathbf{A}^{-1} \mathbf{x} \mathbf{y}^\top \mathbf{A}^{-1} d\mathbf{A}) \end{aligned}$$

同理, 求得其梯度。

(4 分)

题 5 (13') 计算和证明以下问题:

(1) 同时抛 2 颗骰子, 事件 A, B, C 分别表示为

(A) 仅有一个骰子是 3

(B) 至少一个骰子是 4

(C) 骰子上点数总和为 7

试计算事件 A, B, C 发生后所提供的信息量;

(2) 证明联合熵和条件熵有如下关系:

$$H(X, Y) = H(X) + H(Y | X)$$

解 (1) $H_A = -\log \frac{5}{18}, H_B = -\log \frac{1}{6}, H_C = -\log \frac{1}{2}$ (6 分) (2)

$$\begin{aligned} H(X, Y) &= \mathbb{E}(\log \frac{1}{p(xy)}) \\ &= \mathbb{E}(\log \frac{1}{p(x)p(y|x)}) \\ &= \mathbb{E}(\log \frac{1}{p(x)} + \log \frac{1}{p(y|x)}) \\ &= \mathbb{E}(\log \frac{1}{p(x)}) + \mathbb{E}(\log \frac{1}{p(y|x)}) \\ &= H(X) + H(Y|X) \end{aligned}$$

(7 分)

题 6 (12') 求解以下问题:

(1) 假设总体 $X \sim N(\mu, \sigma_0^2)$ (σ_0^2 已知), X_1, X_2, \dots, X_n 为来自总体 X 的样本, 由过去的经验和知识, 我们可以确定 μ 的取值比较集中在 $\hat{\mu}$ 附近, 离 $\hat{\mu}$ 越远, μ 取值的可能性越小, 于是我们假定 μ 的先验分布为正态分布

$$\pi(\mu) = \frac{1}{\sqrt{2\pi\hat{\sigma}^2}} \exp \left[-\frac{1}{2\hat{\sigma}^2} (\mu - \hat{\mu})^2 \right] \quad (\hat{\mu}, \hat{\sigma} \text{ 已知})$$

求 μ 的后验概率分布。

- (2) 假设总体 $X \sim P(\lambda)$, X_1, X_2, \dots, X_n 为来自总体 X 的样本, 假定 λ 的先验分布为伽玛分布 $\Gamma(\alpha, \beta)$, 求 λ 的后验期望估计 (泊松分布的分布律: $P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$, 泊松分布的期望为 λ ; 伽马分布的概率密度函数: $f(x; \alpha, \beta) = \frac{x^{\alpha-1} e^{-\beta x} \beta^\alpha}{\Gamma(\alpha)}$, 伽马分布的期望为 α/β).

解 (1) 样本分布密度为

$$q(\mathbf{x} | \mu) = \frac{1}{\sigma_0^n (2\pi)^{n/2}} \exp \left[-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2 \right]$$

于是后验密度函数为

$$\begin{aligned} h(\mu | \mathbf{x}) &= \frac{q(\mathbf{x} | \mu) \cdot \pi(\mu)}{f_{\mathbf{x}}(\mathbf{x})} = \frac{q(\mathbf{x} | \mu) \cdot \pi(\mu)}{\int_{-\infty}^{+\infty} q(\mathbf{x} | \mu) \cdot \pi(\mu) d\mu} \\ &\propto \exp \left[-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2 \right] \cdot \exp \left[-\frac{1}{2\hat{\sigma}^2} (\mu - \hat{\mu})^2 \right] \end{aligned}$$

化简得

$$h(\mu | \mathbf{x}) \propto \exp \left[-\frac{(\mu - t)^2}{2\eta^2} \right]$$

其中 $t = \frac{\frac{n}{\sigma_0^2} \bar{x} + \frac{1}{\sigma_\mu^2} \hat{\mu}}{\frac{n}{\sigma_0^2} + \frac{1}{\sigma_\mu^2}}$, $\eta^2 = \frac{1}{\frac{n}{\sigma_0^2} + \frac{1}{\sigma_\mu^2}}$, 于是

$$\mu | \mathbf{x} \sim N \left(\frac{\frac{n}{\sigma_0^2} \bar{x} + \frac{1}{\sigma_\mu^2} \hat{\mu}}{\frac{n}{\sigma_0^2} + \frac{1}{\sigma_\mu^2}}, \frac{1}{\frac{n}{\sigma_0^2} + \frac{1}{\sigma_\mu^2}} \right).$$

(6 分)

- (2) 因为 λ 的先验密度函数 $\pi(\lambda)$ 为伽玛分布 $\Gamma(\alpha, \beta)$, 即

$$\pi(\lambda) \propto \lambda^{\alpha-1} e^{-\beta\lambda}$$

样本分布密度函数为:

$$q(\mathbf{x} | \lambda) = \frac{\lambda^{\sum_{i=1}^n x_i}}{x_1! x_2! \dots, x_n!} e^{-n\lambda} \propto \lambda^{\sum_{i=1}^n x_i} e^{-n\lambda}$$

所以

$$h(\lambda \mid \mathbf{x}) \propto \lambda^{\alpha + \sum_{i=1}^n x_i - 1} e^{-(\beta + n)\lambda}$$

即

$$\lambda \mid \mathbf{x} \sim \Gamma\left(\alpha + \sum_{i=1}^n x_i, \beta + n\right)$$

故 λ 的后验期望估计为

$$\hat{\lambda} = \frac{\alpha + \sum_{i=1}^n x_i}{\beta + n} = \frac{n}{\beta + n} \bar{x} + \frac{\beta}{\beta + n} \frac{\alpha}{\beta}$$

它是样本均值 \bar{x} 和先验分布 $\Gamma(\alpha, \beta)$ 的均值 $\frac{\alpha}{\beta}$ 的加权平均。

(6 分)

题 7 (12') 求证下列与凸集或凸函数相关的问题:

- (1) 证明: 设 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 是仿射变换, 即 $f(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$, $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}^m$, 则凸集在 f 下的像是凸集:

$$S \subseteq \mathbb{R}^n \text{ 为凸集} \Rightarrow f(S) \stackrel{\text{def}}{=} \{f(\mathbf{x}) \mid \mathbf{x} \in S\} \text{ 为凸集};$$

- (2) 判定函数 $f(\mathbf{x}) = \max(\|\mathbf{A}\mathbf{x} + \mathbf{b}\|_2, \|\mathbf{x}^\top \mathbf{x}\|_1)$, $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{b} \in \mathbb{R}^m$ 是否为凸函数, 并说明理由。

解 (1) 令 $\mathbf{y}_1, \mathbf{y}_2$ 表示再像集合中的任意两个点, 它们的原象分别为 $\mathbf{x}_1, \mathbf{x}_2$ 。因此, $\mathbf{y}_1 = \mathbf{A}\mathbf{x}_1 + \mathbf{b}$, $\mathbf{y}_2 = \mathbf{A}\mathbf{x}_2 + \mathbf{b}$ 因此, 有

$$(1 - \lambda)\mathbf{y}_1 + \lambda\mathbf{y}_2 = \mathbf{A}((1 - \lambda)\mathbf{x}_1 + \lambda\mathbf{x}_2) + \mathbf{b}$$

故得证。

(6 分)

(2) 由仿射函数的任意范数为凸函数可知 $\|\mathbf{A}\mathbf{x} + \mathbf{b}\|_2$ 为凸函数, 另外 $\|\mathbf{x}^\top \mathbf{x}\|_1$ 为欧几里得范数的平方, 显然为凸函数。根据逐点取最大值具有保凸性, 可知 $f(\mathbf{x})$ 是凸函数。

(6 分)

题 8 (11') 考虑优化问题

$$\min_{\mathbf{x}} \quad \mathbf{x}^T \mathbf{W} \mathbf{x}$$

其中 $\mathbf{W} \in S_+^n$ 是对称半正定矩阵。

(1) 求出在任意点 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ 处沿负梯度方向迭代的最佳步长 α 。

(2) 若对上述优化问题增加约束条件

$$x_i^2 = 1, \quad i = 1, \dots, n$$

请写出此时约束优化问题的拉格朗日函数 $L(\mathbf{x}, \boldsymbol{\lambda})$ ，并计算出约束优化问题的拉格朗日对偶函数。

解 (1) 可求得 $f(\mathbf{x}) = \mathbf{x}^T \mathbf{W} \mathbf{x}$ 的梯度为 $2\mathbf{W}\mathbf{x}$ 。因此，为寻求得最佳步长，需求解

$$\min_{\mathbf{x}} \quad (\mathbf{x} - 2\alpha\mathbf{W}\mathbf{x})^T \mathbf{W} (\mathbf{x} - 2\alpha\mathbf{W}\mathbf{x}) \quad (2 \text{ 分})$$

求极值可得：

$$\alpha = \frac{\mathbf{x}^T \mathbf{W}^2 \mathbf{x}}{2\mathbf{x}^T \mathbf{W}^3 \mathbf{x}}. \quad (3 \text{ 分})$$

(2) 若增加约束条件，可得 Lagrange 函数为

$$\begin{aligned} L(\mathbf{x}, \boldsymbol{\nu}) &= \mathbf{x}^T \mathbf{W} \mathbf{x} + \sum_{i=1}^n \nu_i (x_i^2 - 1) \\ &= \mathbf{x}^T (\mathbf{W} + \text{diag}(\boldsymbol{\nu})) \mathbf{x} - \mathbf{1}^T \boldsymbol{\nu} \end{aligned} \quad (3 \text{ 分})$$

对 \mathbf{x} 求极小得到 Lagrange 对偶函数

$$\begin{aligned} g(\boldsymbol{\nu}) &= \inf_{\mathbf{x}} \mathbf{x}^T (\mathbf{W} + \text{diag}(\boldsymbol{\nu})) \mathbf{x} - \mathbf{1}^T \boldsymbol{\nu} \\ &= \begin{cases} -\mathbf{1}^T \boldsymbol{\nu} & \mathbf{W} + \text{diag}(\boldsymbol{\nu}) \succeq \mathbf{0} \\ -\infty & \text{其他情况} \end{cases} \end{aligned}$$

(3 分)