

2021 级华东师范大学本科生期末考试

《数据科学与工程数学基础》笔试试卷 2023.2

学院：数据科学与工程学院 考试形式：闭卷 所需时间：120 分钟

考生姓名：_____ 学号：_____ 专业：_____ 任课教师：黄定江

题目	一	二	三	四	五	六	七	八	总分
满分	13	12	12	13	13	12	13	12	100
得分									
阅卷人									

题 1 (13') 假设 $Q \in \mathbb{R}^{n \times n} \setminus \{0\}$ 是一个投影矩阵.

- (1) 证明: $Qz = z, \forall z \in \mathcal{R}(Q)$ 以及 $Qy - y \in \mathcal{N}(Q), \forall y \in \mathbb{R}^n$.
- (2) 证明: Q 的特征值 $\lambda \in \Lambda(Q) \subseteq \{0, 1\}$.
- (3) 假设 $\mathcal{R}(Q) = \text{span}(u_1, \dots, u_r)$, $\mathcal{N}(Q) = \text{span}(v_{r+1}, \dots, v_n)$ 这里 r 表示投影矩阵的秩, 请据此写出 Q 的特征分解 $Q = XDX^{-1}$ 的具体形式.
- (4) 证明: 当 $Q \neq I_n$, $\det(Q) = 0$.

解 (1) $\forall y \in \mathcal{R}(Q)$ 必存在 $x \in \mathbb{R}^n$, 使得 $y = Qx$ 成立. 因此, $Qy = Q^2x = Qx = y$. 另外, $\forall x \in \mathbb{R}^n$, $Q(Qx - x) = Q^2x - Qx = Qx - Qx = 0$. (3 分)

(2) 对 $\lambda \in \Lambda(Q)$, $x \in \mathbb{R}^n \setminus \{0\}$, 有 $Qx = \lambda x$. 由于 $Q = Q^2$, $\lambda x = Qx = Q(Qx) = Q(\lambda x) = \lambda Qx = \lambda^2 x$. 因为 $x \neq 0 \in \mathbb{R}^n$, 故 $\lambda = \lambda^2$, $\lambda \in \{0, 1\}$. 因此 $\Lambda(Q) \subseteq \{0, 1\}$. (3 分)

(3) 由 (1) 可知, $\forall i = 1, \dots, r, u_i \in \mathcal{R}(Q), Qu_i = u_i$, 以及 $\forall j = r+1, \dots, n, v_j \in \mathcal{N}(Q), Qv_j = 0$. 故令

$$X := (u_1 | \cdots | u_r | v_{r+1} | \cdots | v_n) \in \mathbb{R}^{n \times n},$$

$$D := \text{diag}_{n \times n}(\underbrace{1, \dots, 1}_{r \text{ times}}, 0, \dots, 0) \in \mathbb{R}^{n \times n},$$

此时 $Q = XDX^{-1}$. (4 分)

(3) 反证 $\det(Q) \neq 0 \implies Q = I_n$. 由于 $\det(Q) \neq 0$, 故 Q 可逆. 故由 $Q^2 = Q$, 得 $Q^{-1}Q^2 = Q^{-1}Q$, 即 $Q = I_n$. (3 分)

题 2 (12') 已知矩阵

$$M = \begin{pmatrix} 0 & -3 & 3 \\ 0 & 0 & 4 \\ 2 & 1 & 1 \end{pmatrix}$$

(1) 先求矩阵 M 的 QR 分解, 然后根据 QR 分解求解方程组 $Mx = b$, 其中 $b = [6, 4, 1]^T$;

(2) 请根据你对 LU 分解、Cholesky 分解和 QR 分解的理解, 谈谈它们之间的联系与差异。

解 (1) 因为 $\alpha_1 = (0, 0, 2)^T$, 记 $a_1 = \|\alpha_1\|_2 = 2$, 令 $w_1 = \frac{\alpha_1 - a_1 e_1}{\|\alpha_1 - a_1 e_1\|_2} = \frac{1}{\sqrt{2}}(-1, 0, 1)^T$, 则

$$H_1 = I - 2w_1 w_1^H = \begin{pmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix}$$

从而

$$\mathbf{H}_1 \mathbf{M} = \begin{pmatrix} 2 & 1 & 1 \\ 0 & 0 & 4 \\ 0 & -3 & 3 \end{pmatrix}$$

记 $\beta = (0, -3)^T$, 则 $b_2 = \|\beta_2\|_2 = 3$, 令 $\mathbf{w}_2 = \frac{\beta_2 - b_2 \mathbf{e}_1}{\|\beta_2 - b_2 \mathbf{e}_1\|_2} = \frac{1}{\sqrt{2}}(-1, -1)^T$

$$\widetilde{\mathbf{H}}_2 = \mathbf{I} - 2\mathbf{w}_2\mathbf{w}_2^H = \begin{pmatrix} 0 & -1 \\ -1 & 0 \end{pmatrix}$$

记

$$\mathbf{H}_2 = \begin{pmatrix} 1 & 0^T \\ 0 & \widetilde{\mathbf{H}}_2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & -1 \\ 0 & -1 & 0 \end{pmatrix}$$

则

$$\mathbf{H}_2(\mathbf{H}_1 \mathbf{M}) = \begin{pmatrix} 2 & 1 & 1 \\ 0 & 3 & -3 \\ 0 & 0 & -4 \end{pmatrix} = \mathbf{R}$$

易知 $\mathbf{R}\mathbf{x} = \mathbf{H}_2\mathbf{H}_1\mathbf{b} = (1, -6, -4)^T$, 故可求得 $\mathbf{x} = (1/2, -1, 1)^T$ (7分)

(2) (总体上, 只要理解正确即可) 这三种分解方式的联系在于将一个非三角矩阵转化为三角矩阵, 这样便可以有效提高实际应用中一系列方程组求解的效率。它们区别在于 LU 分解和 Cholesky 分解是基于高斯消去法, 分别适用于一般地可逆矩阵和对称矩阵, QR 分解则是利用正交投影的方法, 将向量分别投影到左边平面上的方式, 从而达到对角化。 (5分)

题 3 (12') 完成下列矩阵函数求梯度:

(1) 求行列式函数 $f(\mathbf{X}) = |\mathbf{X}^3|$ 的梯度矩阵, 其中变量 $\mathbf{X} \in \mathbb{R}^{n \times n}$ 非奇异;

(2) 求迹函数 $f(\mathbf{X}) = \text{Tr}(\mathbf{X}^T \mathbf{X}^{-1} \mathbf{A})$ 的梯度矩阵, 其中变量 $\mathbf{X} \in \mathbb{R}^{n \times n}$ 非奇异。

解 (1) 因为 $d|\mathbf{X}| = \text{Tr}(|\mathbf{X}|\mathbf{X}^{-1}d\mathbf{X})$, 因此

$$\begin{aligned} d(|\mathbf{X}^3|) &= \text{Tr}(\mathbf{X}\mathbf{X}^{-3}d\mathbf{X}^3) \\ &= \text{Tr}(|\mathbf{X}^3|\mathbf{X}^{-3}(d\mathbf{X} \cdot \mathbf{X}^2 + \mathbf{X}d\mathbf{X} \cdot \mathbf{X} + \mathbf{X}^2d\mathbf{X})) \\ &= \text{Tr}(3|\mathbf{X}|^3\mathbf{X}^{-1}d\mathbf{X}) \end{aligned}$$

所以梯度矩阵 $3|\mathbf{X}|^3(\mathbf{X}^{-1})^\top$ 。

(6 分)

(2)

$$\begin{aligned} d\text{Tr}(\mathbf{X}^\top \mathbf{X}^{-1} \mathbf{A}) &= \text{Tr}(d(\mathbf{X}^\top \mathbf{X}^{-1} \mathbf{A})) \\ &= \text{Tr}(d\mathbf{X}^\top \mathbf{X}^{-1} \mathbf{A} - \mathbf{X}^\top \mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1} \mathbf{A}) \\ &= \text{Tr}((\mathbf{A}^\top (\mathbf{X}^{-1})^\top - \mathbf{X}^{-1} \mathbf{A} \mathbf{X}^\top \mathbf{X}^{-1}) d\mathbf{X}) \end{aligned}$$

即

$$\frac{\partial \text{Tr}(\mathbf{X}^\top \mathbf{X}^{-1} \mathbf{A})}{\partial \mathbf{X}} = (\mathbf{A}^\top (\mathbf{X}^{-1})^\top - \mathbf{X}^{-1} \mathbf{A} \mathbf{X}^\top \mathbf{X}^{-1})^\top$$

(6 分)

题 4 (13') 矩阵

$$\mathbf{A} = \begin{pmatrix} 7/5 & -1/5 \\ 1/5 & 7/5 \\ 0 & 0 \end{pmatrix}$$

(1) 计算矩阵 \mathbf{A} 的 SVD 分解;

(2) 假设 \mathbf{M} 是任意一个非奇异 $n \times d$ 的矩阵, 已知其奇异值分解为 $\mathbf{M} = \mathbf{U}\Sigma\mathbf{V}^\top$, 其中 $\mathbf{U} = [u_1, u_2, \dots, u_n]$, $\Sigma = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$, $\mathbf{V} = [v_1, v_2, \dots, v_n]$ 。请分别写出矩阵 \mathbf{M} 的逆矩阵的 SVD 分解;

(3) 请写出 (2) 中 \mathbf{M} 的转置矩阵的 SVD 分解。

解 (1) 易计算

$$\mathbf{A}^\top \mathbf{A} = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

求得其特征值为 2, 9。对应的特征向量分别为 $(1, 0)^\top, (0, 1)^\top$ ，因此，

$$\mathbf{V} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

(3 分)

由 $\mathbf{A}\mathbf{V}$ 与 \mathbf{U} 的关系可直接计算出

$$\mathbf{U} = \begin{pmatrix} 7/5\sqrt{2} & -1/5\sqrt{2} & 0 \\ 1/5\sqrt{2} & 7/5\sqrt{2} & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

(3 分)

(2) 因为 \mathbf{M} 的 SVD 分解为

$$\mathbf{M} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top = (u_1 | \cdots | u_n) [\text{diag}_{n \times n}(\lambda_1, \dots, \lambda_n)] (v_1 | \cdots | v_n)^\top$$

其中 $\mathbf{U}, \mathbf{V} \in \mathbb{R}^{n \times n}$ 正交, $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n \geq 0$ 。因为 \mathbf{M} 可逆, 有 $\text{rank}(\mathbf{M}) = n$, 故 $\lambda_i > 0, \forall i \in \{1, \dots, n\}$ 。又由 $\mathbf{M} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$ 有 $\mathbf{M}v_i = \lambda_i u_i \forall i \in \{1, \dots, n\}$, 因此

$$\mathbf{M}^{-1}u_i = \mathbf{M}^{-1}\left(\frac{1}{\lambda_i}\mathbf{M}v_i\right) = \frac{1}{\lambda_i}v_i$$

其中 $\frac{1}{\lambda_n} \geq \cdots \geq \frac{1}{\lambda_2} \geq \frac{1}{\lambda_1} > 0$ 。综上

$$\mathbf{M}^{-1} = (v_n | \cdots | v_2 | v_1) \left[\text{diag}_{n \times n} \left(\frac{1}{\lambda_n}, \dots, \frac{1}{\lambda_2}, \frac{1}{\lambda_1} \right) \right] (u_n | \cdots | u_2 | u_1)^\top,$$

整理可得

$$\mathbf{M}^{-1} = (\mathbf{V}\mathbf{P}) (\mathbf{P}\mathbf{\Sigma}^{-1}\mathbf{P}) (\mathbf{U}\mathbf{P})^\top.$$

记 $\mathbf{P} := (e_n | \cdots | e_2 | e_1) \in \mathbb{R}^{n \times n}$ 。(由于 $\mathbf{P}\mathbf{P}^\top = \mathbf{P}^2 = \mathbf{I}_n$, \mathbf{P} 是正交阵, 且 $\mathbf{V}\mathbf{P}$, $\mathbf{U}\mathbf{P}$ 是正交阵)。

(5 分)

(3) 因为 \mathbf{M} 的 SVD 分解为

$$\mathbf{M} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$$

其中 $\mathbf{U}, \mathbf{V} \in \mathbb{R}^{n \times n}$ 正交。易得

$$\mathbf{M}^T = \mathbf{V}\mathbf{\Sigma}\mathbf{U}^T.$$

显然 \mathbf{V}, \mathbf{U} 是正交阵。

(2 分)

题 5 (13') 已知矩阵

$$\mathbf{M} = \begin{pmatrix} 2 & 0 \\ -1 & 2 \\ 0 & 3 \end{pmatrix}$$

(1) 计算矩阵 \mathbf{M} 的 1 范数和 ∞ 范数;

(2) 计算矩阵 \mathbf{M} 的 F 范数和 2 范数。

(3) 试比较任意矩阵 \mathbf{A} 的 F 范数和 2 范数的大小, 并给出理由。

解 (1)

$$\|\mathbf{M}\|_1 = \max\{2 + \|-1\|, 0 + 2 + 3\} = 5$$

$$\|\mathbf{M}\|_\infty = \max\{2 + \|0\|, \|-1\| + 2, 0 + 3\} = 3$$

(4 分)

$$(2) \mathbf{M}^T \mathbf{M} = \begin{pmatrix} 5 & -2 \\ -2 & 13 \end{pmatrix}$$

$$\lambda_{\max}(\mathbf{M}^T \mathbf{M}) = 9 + 2\sqrt{2}$$

$$\|\mathbf{M}\|_2 = \sqrt{9 + 2\sqrt{2}}$$

$$\text{易求得 } \|\mathbf{M}\|_F = \sqrt{18} = 3\sqrt{2}$$

(5 分)

(3) 显然 F 范数大于 2 范数, 因为 F 范数的平方是所有奇异值的平方之和, 而 2 范数的平方是最大奇异值的平方, 因此可知这一点成立。

(4 分)

题 6 (12') 求解以下问题:

(1) 证明: Gauss 概率密度函数的累积分布函数

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-u^2/2} du$$

是对数-凹函数. 即 $\log(\Phi(x))$ 是凹函数。

(2) 设总体 $X \sim E(\theta)$, X_1, X_2, \dots, X_n 为来自总体 X 的样本, θ 的先验分布为指数分布 $E(\lambda)$ (λ 已知), 求 θ 的最大后验估计。

解 (1) 由题意得,

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-u^2/2} du$$

$$\Phi'(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

$$\Phi''(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2} (-x)$$

$$(\Phi'(x))^2 = \frac{1}{2\pi} e^{-x^2}$$

$$\Phi(x) \log \Phi''(x) = \frac{1}{2\pi} \int_{-\infty}^x e^{-u^2/2} du \cdot e^{-x^2/2} (-x)$$

(3 分)

当 $x \geq 0$ 时, $(\Phi'(x))^2 \geq 0 \geq \Phi(x)\Phi''(x)$.

当 $x < 0$ 时, 由于 $\frac{u^2}{2}$ 是凸函数, 则

$$\frac{u^2}{2} \geq \frac{x^2}{2} + (u-x)x \geq xu - \frac{x^2}{2}$$

所以,

$$\begin{aligned} \int_{-\infty}^x e^{-u^2/2} du &\leq \int_{-\infty}^x e^{\frac{x^2}{2} - xu} du \\ &= e^{\frac{x^2}{2} \cdot \frac{e^{-xu}}{-x}} \Big|_{u=-\infty}^x \end{aligned}$$

$$= e^{\frac{x^2}{2}} \cdot \frac{e^{-x^2}}{-x}$$

因此 $\Phi(x)\Phi''(x) \leq \frac{1}{2\pi}e^{-x^2} = (\Phi'(x))^2$, $\Phi(x)$ 是对数凹函数.

(3 分)

(2) 因为先验概率密度函数为:

$$\pi(\theta) = \begin{cases} \lambda e^{-\lambda\theta} & \theta > 0 \\ 0 & \theta \leq 0 \end{cases}$$

样本 (X_1, X_2, \dots, X_n) 的联合概率密度为:

$$q(\mathbf{x} | \theta) = \prod_{n=2}^n f(x_i | \theta) = \begin{cases} \theta^n e^{-\theta \sum_{i=1}^n x_i} & x_1, x_2, \dots, x_n > 0 \\ 0 & \text{其它} \end{cases}$$

所以 θ 的后验分布密度

$$\begin{aligned} h(\theta | \mathbf{x}) &\propto \theta^n e^{-(\lambda + \sum_{i=1}^n x_i)\theta} \\ \ln h(\theta | \mathbf{x}) &= n \ln \theta - \left(\lambda + \sum_{i=1}^n x_i \right) \theta + \ln c(\mathbf{x}) \\ \frac{\partial \ln h(\theta | \mathbf{x})}{\partial \theta} &= \frac{n}{\theta} - \left(\lambda + \sum_{i=1}^n x_i \right) = 0 \end{aligned}$$

求得 θ 的最大后验估计为 $\hat{\theta} = \frac{1}{\bar{x} + \lambda/n}$ 。当 $n \rightarrow \infty$ 时, $\hat{\theta} \rightarrow \frac{1}{\bar{x}}$, 与传统意义下的极大似然估计是一致的.

(6 分)

题 7 (13') 求解下述问题:

(1) 写出下述非线性规划的 KKT 条件, 并求解

$$\begin{aligned} &\text{maximize} && f(x) = (x - 4)^2 \\ &\text{subject to} && 1 \leq x \leq 5 \end{aligned}$$

(2) 用 Lagrange 乘子法证明: 矩阵 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 的 2 范数

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|_2=1, \mathbf{x} \in \mathbb{R}^n} \|\mathbf{A}\mathbf{x}\|_2$$

的平方是 $\mathbf{A}^T \mathbf{A}$ 的最大特征值。

解 (1) 原问题等价于

$$\begin{cases} \text{minimize} & -f(x) = (x-4)^2 \\ g_1(x) = -x+1 \leq 5 \\ g_2(x) = x-5 \leq 0 \end{cases}$$

求目标函数和约束函数的梯度得,

$$\nabla_x f(x) = -2(x-4), \nabla_x g_1(x) = -1, \nabla_x g_2(x) = 1$$

将约束引入广义 Lagrange 乘子 v_1, v_2 , 在 KKT 条件上有

$$\begin{cases} -2(x^* - 4) - v_1^* + v_2^* = 0 \\ v_1^*(-x^* + 1) = 0 \\ v_2^*(x^* - 5) = 0 \\ v_1^* \geq 0, v_2^* \geq 0 \end{cases}$$

(4 分)

若 $v_1^* \neq 0, v_2^* \neq 0$, 无解.

若 $v_1^* = 0, v_2^* \neq 0$, 得 $x^* = 5, v_2^* = 2, -f(x^*) = -1$.

若 $v_1^* \neq 0, v_2^* = 0$, 得 $x^* = 1, v_1^* = 6, -f(x^*) = -9$.

若 $v_1^* = 0, v_2^* = 0$, 得 $x^* = 4, f(x^*) = 0$.

因此最优点 $x^* = 1, \text{maximize} f(x) = 9$.

(3 分)

(2) 优化问题为

$$\begin{aligned} & \text{maximize} \quad f(\mathbf{x}) = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} \\ & \text{subject to} \quad \mathbf{x}^T \mathbf{x} = 1 \end{aligned}$$

Lagrange 函数为:

$$\begin{aligned} L(\mathbf{x}) &= \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} - \lambda(\mathbf{x}^T \mathbf{x} - 1) \\ \frac{\partial L}{\partial \mathbf{x}} &= 2\mathbf{A}^T \mathbf{A} \mathbf{x} - 2\lambda \mathbf{x} \end{aligned}$$

令 $\frac{\partial L}{\partial \mathbf{x}} = 0$, 有:

$$\mathbf{A}^T \mathbf{A} \mathbf{x} = \lambda$$

(3 分)

这表示在 $f(\mathbf{x})$ 的极大值点, \mathbf{x} 是 $\mathbf{A}^T \mathbf{A}$ 的特征向量, λ 是对应的特征值。此时,

$$f(\mathbf{x}) = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{x}^T \lambda \mathbf{x} = \lambda \mathbf{x}^T \mathbf{x} = \lambda$$

因此说明, 为使 $f(\mathbf{x})$ 最大, $f(\mathbf{x}) = \lambda_{\max}(\mathbf{A}^T \mathbf{A})$, 其中 λ_{\max} 表示最大特征值。即

$$\|\mathbf{A}\|_2^2 = \lambda_{\max}(\mathbf{A}^T \mathbf{A})$$

(3 分)

题 8 (12') 求解如下优化问题

(1) 考虑问题

$$\min f(\mathbf{x}) = 3x_1^2 + 3x_2^2 - 2x_1^2 x_2.$$

从初始点 $\mathbf{x}^{(0)} = (0, 1)^T$ 出发, 写出用最速下降法迭代两步的求解过程, 并说明迭代是否可以终止。

(2) 尽管牛顿法在求解无约束优化问题时, 具有更高阶的收敛速度, 但在处理大规模问题时, 该方法涉及的 Hessian 矩阵及其逆矩阵的计算是非常耗时的。因此, 研究者们探究了对 Hessian 矩阵逆近似的迭代方法, 也就是拟牛顿法或变尺度法。通常这样近似 Hessian 矩阵或逆矩阵需要保持原有的性质, 即满足割线方程:

$$\Delta \mathbf{x}^{(k)} = \bar{H}^{(k+1)} \Delta \mathbf{g}^{(k)},$$

其中 $\bar{H}^{(k)}$ 表示矩阵的 Hessian 矩阵逆的近似。如果已经得到上一轮迭代时的近似 $\bar{H}^{(k)}$, 则一般地做法是通过秩一修正或秩二修正得到下一轮的近似矩阵 $\bar{H}^{(k+1)}$ 。当采用秩二修正时, 便得到著名的 DFP 法。现已知第 k 次迭代时的 $\Delta \mathbf{x}^{(k)}, \bar{H}^{(k)}, \Delta \mathbf{g}^{(k)}$, 请给出下一轮迭代的 Hessian 矩阵逆的近似的推导过程。

解 (1) 由题意得, $\nabla_{\mathbf{x}} f(\mathbf{x}) = (6x_1 - 4x_1x_2, 6x_2 - 2x_1^2)^T$, 故 $g^{(0)} = \nabla_{\mathbf{x}} f(\mathbf{x}^{(0)}) = (0, 6)$ 。现设最速下降法的步长为 λ , 那么

$$f(\mathbf{x}^{(0)} - \lambda g^{(0)}) = 3(1 - 6\lambda^2)$$

在 $\nabla_{\mathbf{x}} f(\mathbf{x}^{(0)})$ 方向上, 使 $f(\mathbf{x})$ 最小的 λ 为

$$\lambda = \frac{1}{6}$$

所以,

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} - \frac{1}{2} \nabla_{\mathbf{x}} f(\mathbf{x}^{(0)}) = (0, 0)^T$$

易知此时 $\mathbf{x}^{(1)}$ 处的梯度已经为 0, 可见已经收敛。显然

$$\mathbf{x}^{(2)} = (0, 0)^T$$

(7 分)

(2) 可设

$$\overline{\mathbf{H}}^{(k+1)} = \overline{\mathbf{H}}^{(k)} + a\mathbf{u}\mathbf{u}^T + b\mathbf{v}\mathbf{v}^T$$

其中 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$, $a, b \in \mathbb{R}$ 待定。

同上所述, 仍然利用割线方程, 有

$$\begin{aligned} \Delta \mathbf{x}^{(k)} &= \overline{\mathbf{H}}^{(k+1)} \Delta \mathbf{g}^{(k)} \\ &= (\overline{\mathbf{H}}^{(k)} + a\mathbf{u}\mathbf{u}^T + b\mathbf{v}\mathbf{v}^T) \Delta \mathbf{g}^{(k)} \end{aligned}$$

整理得

$$a(\mathbf{u}^T \Delta \mathbf{g}^{(k)})\mathbf{u} + b(\mathbf{v}^T \Delta \mathbf{g}^{(k)})\mathbf{v} = \Delta \mathbf{x}^{(k)} - \overline{\mathbf{H}}^{(k)} \Delta \mathbf{g}^{(k)}.$$

因此, \mathbf{u}, \mathbf{v} 的线性组合等于 $\Delta \mathbf{x}^{(k)} - \overline{\mathbf{H}}^{(k)} \Delta \mathbf{g}^{(k)}$ 。同样地, 不妨令 $\mathbf{u} = \Delta \mathbf{x}^{(k)}$, $\mathbf{v} = \overline{\mathbf{H}}^{(k)} \Delta \mathbf{g}^{(k)}$, 则代入可得

$$\begin{aligned} a &= \frac{1}{(\Delta \mathbf{x}^{(k)})^T \Delta \mathbf{g}^{(k)}}, \\ b &= -\frac{1}{(\Delta \mathbf{g}^{(k)})^T \overline{\mathbf{H}}^{(k)} \Delta \mathbf{g}^{(k)}}. \end{aligned}$$

从而，得到更新公式：

$$\overline{\mathbf{H}}^{(k+1)} = \overline{\mathbf{H}}^{(k)} + \frac{\Delta \mathbf{x}^{(k)} \Delta \mathbf{x}^{(k)T}}{(\Delta \mathbf{x}^{(k)})^T \Delta \mathbf{g}^{(k)}} - \frac{\overline{\mathbf{H}}^{(k)} \Delta \mathbf{g}^{(k)} (\overline{\mathbf{H}}^{(k)} \Delta \mathbf{g}^{(k)})^T}{(\Delta \mathbf{g}^{(k)})^T \overline{\mathbf{H}}^{(k)} \Delta \mathbf{g}^{(k)}}.$$

(5 分)