

华东师范大学期末试卷 (A 卷) 答案

2023—2024 学年第一学期

考试科目: 数据科学与工程数学基础 任课教师: 黄定江
姓 名: _____ 学 号: _____
专 业: _____ 班 级: _____

题号	一	二	三	四	五	六	七	八	总分	阅卷人签名
得分										

题 1 (13') 完成以下问题:

(1) 对矩阵 $M = \begin{pmatrix} 5 & 3 & -1 & 3 \\ 0 & 1 & 1 & -2 \\ -5 & -3 & 4 & -4 \\ 0 & 1 & 1 & 0 \end{pmatrix}$ 进行 LU 分解;

(2) 设 A 对称且 $a_{11} \neq 0$, 并假经过一步 Gauss 消去之后, A 具有如下形式

$$\begin{bmatrix} a_{11} & a_1^T \\ \mathbf{0} & A_2 \end{bmatrix}$$

证明: A_2 仍是对称矩阵。

解 (1)

$$A = \begin{pmatrix} 5 & 3 & -1 & 3 \\ 0 & 1 & 1 & -2 \\ -5 & -3 & 4 & -4 \\ 0 & 1 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ -1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} 5 & 3 & -1 & 3 \\ 0 & 1 & 1 & -2 \\ 0 & 0 & 3 & -1 \\ 0 & 0 & 0 & 2 \end{pmatrix} = LU$$

(7 分)

(2) 记矩阵 A 和高斯变换矩阵分别为:

$$A = \begin{bmatrix} a_{11} & a_1^T \\ a_1 & A_1 \end{bmatrix}, G = \begin{bmatrix} 1 & \mathbf{0}^T \\ -l_1 & I \end{bmatrix}$$

则

$$GA = \begin{bmatrix} a_{11} & a_1^T \\ -a_{11}l_1 + a_1 & -l_1a_1^T + A_1 \end{bmatrix}$$

易知 $-a_{11}l_1 + a_1 = \mathbf{0}$ 以及 $A_2 = -l_1a_1^T + A_1$ 。由第一个等式可得 $l_1 = 1/a_{11}a_1$, 代入第二个等式知

$$A_2 = -\frac{1}{a_{11}}a_1a_1^T + A_1.$$

故可知 A_2 仍是对称矩阵。

(6 分)

题 2 (10') \mathbb{R}^5 的欧氏空间。子空间 $U \subseteq \mathbb{R}^5$ 和 $\mathbf{x} \in \mathbb{R}^5$ 如下:

$$U = \text{span} \left\{ \begin{bmatrix} 0 \\ -1 \\ 2 \\ 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \\ 1 \\ -1 \\ 1 \end{bmatrix} \right\}, \quad \mathbf{x} = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

请确定 \mathbf{x} 在子空间 U 上的正交投影 $\pi_U(\mathbf{x})$;

解 首先，将 U 中的基向量构成矩阵 A ：

$$A = \begin{bmatrix} 0 & 1 \\ -1 & -1 \\ 2 & 1 \\ 0 & -1 \\ 1 & 1 \end{bmatrix}$$

易计算出

$$A^T A = \begin{bmatrix} 6 & 4 \\ 4 & 5 \end{bmatrix}, \quad (A^T A)^{-1} = \begin{bmatrix} 5/14 & -2/7 \\ -2/7 & 3/7 \end{bmatrix}$$

(4 分)

然后，计算投影矩阵 P_U ：

$$P_U = \begin{bmatrix} 3/7 & -1/7 & -1/7 & -3/7 & 1/7 \\ -1/7 & 3/14 & -2/7 & 1/7 & -3/14 \\ -1/7 & -2/7 & 5/7 & 1/7 & 2/7 \\ -3/7 & 1/7 & 1/7 & 3/7 & -1/7 \\ 1/7 & -3/14 & 2/7 & -1/7 & 3/14 \end{bmatrix}$$

因此，投影

$$\pi_U(x) = P_U x = (-1/7, 3/14, -2/7, 1/7, -3/14)$$

(6 分)

题 3 (13') 完成下列矩阵函数求梯度：

(1) 求函数 $f(\mathbf{x}) = \mathbf{a}^T \mathbf{x}$ 和 $g(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x}$ 的 Hessian 矩阵；

(2) 考虑一个两层的全连接神经网络：

$$\mathbf{y} = \mathbf{f}(\mathbf{x}) = \text{ReLU}(\mathbf{A}_2(\text{ReLU}(\mathbf{A}_1 \mathbf{x} + \mathbf{b}_1)) + \mathbf{b}_2)$$

其中

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 3 \\ -2 & 1 \\ 3 & -1 \end{bmatrix}, \mathbf{A}_2 = \begin{bmatrix} 3 & -1 & 0 \\ 1 & -2 & 2 \end{bmatrix}, \mathbf{b}_1 = \begin{bmatrix} -1 \\ 4 \\ -2 \end{bmatrix}, \mathbf{b}_2 = \begin{bmatrix} 2 \\ -3 \end{bmatrix}$$

假设输入为 $\mathbf{x} = (1, -1)$ ，并且对应的真实输出为 $\hat{\mathbf{y}} = (0, 1)$ ，采用平方损失 $L = \frac{1}{2} \|\mathbf{y} - \hat{\mathbf{y}}\|_2^2$ 。试计算函数 L 关于 \mathbf{b}_1 的梯度。

解 (1) 因为 $\frac{\partial f}{\partial \mathbf{x}} = \mathbf{a}$ ，因此 $H_f = \mathbf{O}$ 。又

$$\begin{aligned} d(g) &= \text{Tr}(d\mathbf{x}^T \cdot \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{x}d\mathbf{x}) \\ &= \text{Tr}(\mathbf{x}^T(\mathbf{A}^T + \mathbf{A})d\mathbf{x}) \end{aligned}$$

所以 Hessian 矩阵 $H_g = \mathbf{A}^T + \mathbf{A}$ 。

(5 分)

(2)

先计算前项过程：

$$\mathbf{A}_1\mathbf{x} + \mathbf{b}_1 = \begin{bmatrix} -2 \\ 1 \\ 2 \end{bmatrix}, \mathbf{A}_2(\text{ReLU}(\mathbf{A}_1\mathbf{x} + \mathbf{b}_1)) + \mathbf{b}_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

故 $\mathbf{y} = (1, 0)$ ，从而 $L = 1$ 。记

$$\mathbf{k} = \text{ReLU}(\mathbf{A}_1\mathbf{x} + \mathbf{b}_1)$$

然后分别计算

$$\frac{\partial L}{\partial \mathbf{y}} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \frac{\partial \mathbf{y}^T}{\partial \mathbf{k}} = \begin{bmatrix} 3 & 0 \\ -1 & 0 \\ 0 & 0 \end{bmatrix}, \frac{\partial \mathbf{k}^T}{\partial \mathbf{b}_1} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

所以有

$$\frac{\partial L}{\partial \mathbf{b}_1} = \frac{\partial \mathbf{k}^T}{\partial \mathbf{b}_1} \frac{\partial \mathbf{y}^T}{\partial \mathbf{k}} \frac{\partial L}{\partial \mathbf{y}} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 3 & 0 \\ -1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ -1 \\ 0 \end{bmatrix}$$

(8 分)

题 4 (13') 完成下列问题:

- (1) 设已知矩阵 $M \in \mathbb{R}^{m \times n}$ 的 SVD 分解为 $U\Sigma V^T$, 请写出拼接矩阵 $A = [M \ M]$ 的奇异值分解;
- (2) 令 A 为 $m \times n$ 矩阵, 且 P 为 $m \times m$ 正交矩阵。证明: PA 与 A 的奇异值相同。并说明矩阵 PA 与 A 的左、右奇异向量有何关系?

解 (1) 因为 $M = U\Sigma V^T$, 因此

$$AA^T = 2MM^T = U \cdot 2\Sigma_{m \times m}^2 \cdot U^T.$$

故 A 的奇异值为 $\sqrt{2}\Sigma_{m \times 2n}$, 左奇异向量构成的正交矩阵就是 U . (3 分)

由 $U^T A$ 与右奇异向量 (设为 V_A) 的关系可直接计算出

$$[\Sigma_{m \times n} V^T \quad \Sigma_{m \times n} V^T] = \sqrt{2}\Sigma_{m \times 2n} V_A^T$$

对比等式两边可得 V_A^T 的前 n 行即为 $[\frac{1}{\sqrt{2}}V^T \quad \frac{1}{\sqrt{2}}V^T]$ 。对此进行正交扩充, 可得

$$V_A^T = \begin{bmatrix} \frac{1}{\sqrt{2}}V^T & \frac{1}{\sqrt{2}}V^T \\ \frac{1}{\sqrt{2}}V^T & -\frac{1}{\sqrt{2}}V^T \end{bmatrix}$$

(4 分)

(2) 因为 $(PA)^T(PA) = A^T P^T P A = A^T A$, 故它们的奇异值相同。

(2 分)

假设 A 的 SVD 分解为

$$A = U\Sigma V^T$$

其中 $U, V \in \mathbb{R}^{n \times n}$ 正交。故

$$PA = PU\Sigma V^T$$

因为 P 为正交矩阵, 因此 PU 为其左奇异向量, V 就是 PA 的右奇异向量。

(4 分)

题 5 (12') 已知矩阵

$$\boldsymbol{M} = \begin{pmatrix} 5 & 1 & 2 \\ -2 & -3 & 4 \\ 1 & 3 & -1 \end{pmatrix}$$

- (1) 计算矩阵 \boldsymbol{M} 的 1 范数和 ∞ 范数;
- (2) 证明: 如果矩阵 $\boldsymbol{A} = [\boldsymbol{a}_1, \boldsymbol{a}_2, \dots, \boldsymbol{a}_n]$ 是按列分块的, 那么 $\|\boldsymbol{A}\|_F^2 = \|\boldsymbol{a}_1\|_2^2 + \|\boldsymbol{a}_2\|_2^2 + \dots + \|\boldsymbol{a}_n\|_2^2$ 。
- (3) 设 a_1, a_2, \dots, a_n 是 n 个正数, 证明: 由

$$\Omega(\boldsymbol{x}) = \left(\sum_{i=1}^n a_i x_i^2 \right)^{\frac{1}{2}}$$

定义的函数 $\Omega: \mathbb{R}^n \rightarrow \mathbb{R}$ 是一个范数。

解 (1)

$$\|\boldsymbol{M}\|_1 = \max\{5 + |-2| + 1, 1 + |-3| + 3, 2 + 4 + |-1|\} = 8$$

$$\|\boldsymbol{M}\|_\infty = \max\{5 + 1 + 2, |-2| + |-3| + 4, 1 + 3 + |-1|\} = 9$$

(2 分)

(2) 因为矩阵 \boldsymbol{A} 的 F 范数的平方是矩阵各元素的平方和, 而 \boldsymbol{a}_1 的 ℓ_2 范数的平方是矩阵第一列元素的平方和, 以此类推, \boldsymbol{a}_n 的 ℓ_2 范数的平方是矩阵第 n 列元素的平方和。因此, 的证

(5 分)

(3) 可以通过定义证明该函数具有范数的非负性、齐次性和三角不等式, 只要证明过程合理即可。

(5 分)

题 6 (12') 求解以下问题:

(1) 假设 $X_1 \rightarrow X_2 \rightarrow X_3 \rightarrow \cdots \rightarrow X_n$ 是一个马尔科夫链，即

$$p(x_1, x_2, \dots, x_n) = p(x_1)p(x_2 | x_1) \cdots p(x_n | x_{n-1})$$

试化简 $I(X_1; X_2, \dots, X_n)$ 。

(2) X 和 Y 是 $\{0, 1, 2, 3\}$ 上的独立、等概率分布的随机变量，求 $H(X + Y)$ 。

解 (1)

$$\begin{aligned} I(X_1; X_2, \dots, X_n) &= H(X_1) - H(X_1 | X_2, \dots, X_n) \\ &= H(X_1) - [H(X_1, X_2, \dots, X_n) - H(X_2, \dots, X_n)] \\ &= H(X_1) - \left[\sum_{i=1}^n H(X_i | X_{i-1}, \dots, X_1) - \sum_{i=2}^n H(X_i | X_{i-1}, \dots, X_2) \right] \\ &= H(X_1) - \left[\left(H(X_1) + \sum_{i=2}^n H(X_i | X_{i-1}) \right) - \left(H(X_2) + \sum_{i=3}^n H(X_i | X_{i-1}) \right) \right] \\ &= H(X_2) - H(X_2 | X_1) \\ &= I(X_2; X_1) \\ &= I(X_1; X_2) \end{aligned}$$

(7 分)

(2)。解： $X + Y$ 的分布律

$X + Y$	0	1	2	3	4	5	6
概率	1/16	2/16	3/16	4/16	3/16	2/16	1/16

因此

$$H(X + Y) = -(2 \frac{1}{16} \log_2 \frac{1}{16} + 2 \frac{2}{16} \log_2 \frac{2}{16} + 2 \frac{3}{16} \log_2 \frac{3}{16} + \frac{4}{16} \log_2 \frac{4}{16})$$

也可以用其他对数，这里可化简也可以不化简。

(5 分)

题 7 (13') 求解下述问题:

- (1) 请计算负熵函数 $f(\mathbf{x}) = \sum_{i=1}^n x_i \log x_i$ 的共轭函数。
- (2) 用 Lagrange 乘子法求欠定方程 $\mathbf{Ax} = \mathbf{b}$ 的最小二范数解, 其中 $\mathbf{A} \in \mathbb{R}^{m \times n}, m \leq n, \text{rank}(\mathbf{A}) = m$ 。

解 (1) 设 $g(x) = \langle x, y \rangle - f(x) = \langle x, y \rangle - \sum_{i=1}^n x_i \log x_i$, 对 x 求梯度可得:

$$\nabla g = [y_1 - \log x_1 - 1 \quad y_2 - \log x_2 - 1 \quad \cdots \quad y_n - \log x_n - 1]^T$$

因此, 可得最优解为 $x_i = e^{y_i-1}$, 代入即得:

$$f^*(\mathbf{y}) = \sum_{i=1}^n e^{y_i-1}.$$

(6 分)

(2) 优化问题为

$$\begin{aligned} \min \quad & f(\mathbf{x}) = \frac{1}{2} \|\mathbf{x}\|_2^2 \\ \text{subject to} \quad & \mathbf{Ax} = \mathbf{b} \end{aligned}$$

Lagrange 函数为:

$$\begin{aligned} L(\mathbf{x}, \boldsymbol{\lambda}) &= \frac{1}{2} \mathbf{x}^T \mathbf{x} - \boldsymbol{\lambda}^T (\mathbf{Ax} - \mathbf{b}) \\ \frac{\partial L}{\partial \mathbf{x}} &= \mathbf{x} - \mathbf{A}^T \boldsymbol{\lambda} \end{aligned}$$

令 $\frac{\partial L}{\partial \mathbf{x}} = 0$, 有:

$$\begin{aligned} \mathbf{x} &= \mathbf{A}^T \boldsymbol{\lambda} \\ g(\boldsymbol{\lambda}) &= -\frac{1}{2} \boldsymbol{\lambda}^T \mathbf{A} \mathbf{A}^T \boldsymbol{\lambda} + \boldsymbol{\lambda}^T \mathbf{b} \end{aligned}$$

令 $\frac{\partial g}{\partial \boldsymbol{\lambda}} = 0$:

$$-\mathbf{A} \mathbf{A}^T \boldsymbol{\lambda} + \mathbf{b} = 0$$

由 $\mathbf{A} \in \mathbb{R}^{m \times n}, \text{rank}(\mathbf{A}) = m$ 得 $\mathbf{A} \mathbf{A}^T$ 可逆, 因此

$$\boldsymbol{\lambda} = (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{b}$$

因此, \mathbf{x} 满足 $\mathbf{Ax} = \mathbf{b}$ 的最小二范数解:

$$\mathbf{x} = \mathbf{A}^T(\mathbf{AA}^T)^{-1}\mathbf{b}$$

(7 分)

题 8 (14') 求解如下优化问题

(1) 使用梯度下降法和固定步长 $\lambda = 0.1$ 计算 $\min f(x) = (x_1 - 1)^2 + 16(x_2 - 2)^2$, 初始点 $x^{(0)} = (3, 2)^T$, 迭代至第三步后终止, 请计算迭代过程中的解、梯度和函数值 (第三步不用计算梯度和函数值, 计算结果保留小数点后两位)。

(2) 请谈谈牛顿法与 BFGS 方法之间的区别与联系。

解 (1) 易求得梯度为:

$$\nabla f = [2(x_1 - 1) \quad 32(x_2 - 2)]^T$$

具体迭代结果:

k	$x^{(k)T}$	g_k^T	f_k
0	(3, 2)	(4, 0)	4
1	(2.6, 2)	(3.2, 0)	2.56
2	(2.28, 2)	(2.56, 0)	1.6384
3	(2.024, 2)		

(8 分)

(2) 牛顿法 (Newton's method) 和 BFGS 算法 (Broyden-Fletcher-Goldfarb-Shanno algorithm) 都是优化算法, 用于求解无约束非线性优化问题。它们都属于迭代优化算法, 但有一些关键的区别。

1. 原理和基本思想:

- 牛顿法：基于二阶导数（Hessian 矩阵）的信息，通过迭代更新当前点的位置，以找到目标函数的极小值点。牛顿法通常收敛速度很快，但需要计算和存储 Hessian 矩阵，这可能在高维问题中成为一个挑战。
- BFGS 算法：也是基于二阶导数的信息，但它通过估计 Hessian 矩阵的逆矩阵来进行迭代。相较于牛顿法，BFGS 不需要直接计算和存储 Hessian 矩阵，这降低了存储和计算的复杂性。

2. 更新规则：

- 牛顿法：通过解线性方程系统来计算下降方向。牛顿法的更新规则是直接基于 Hessian 矩阵和梯度的。
- BFGS 算法：通过迭代更新逆 Hessian 矩阵的估计值，以获得下降方向。BFGS 的更新规则更为复杂，但避免了直接计算 Hessian 矩阵的需求。

3. 收敛性：

- 牛顿法：在适当的条件下，牛顿法通常具有二次收敛性，收敛速度较快，但可能受到 Hessian 矩阵的病态性（ill-conditioning）的影响。
- BFGS 算法：通常也具有二次收敛性，但相对于牛顿法更具有稳定性，特别是在高维问题中，因为它不需要直接处理 Hessian 矩阵。

总体上，只要言之有理，且答到关键点即可给分。

(6 分)